


Le Bureau d'Analyse Terrestre : la salle de lecture

Le dossier du 4 juillet



La flotte s'est posée. Un 4 juillet, au-dessus d'un continent bien peuplé, en plein jour de fête nationale humaine. **208 témoins** ont levé les yeux et l'ont vue.

Mais ce n'était pas un accident de navigation. C'était une recommandation écrite, signée par l'analyste qui occupait votre bureau avant vous, appuyée sur des chiffres exacts tirés de la transmission. L'analyste a disparu le lendemain. Sa chaise est vide, son code n'est nulle part, et son dossier tient en une page.

Vous héritez de sa conclusion, et c'est tout ce qui vous reste de lui.

« Nous n'accusons personne. Nous voulons savoir si ces chiffres étaient faux, ou si c'est nous qui avons mal lu des chiffres justes. Vous nous direz lequel des deux avant midi. »
Le Conseil

Comment on travaille aujourd'hui

On reste sur du projet solo : chacun son poste et son dossier

- **Un repo git tout neuf, créé pour le projet d'aujourd'hui.** Commits courts, réguliers, un par décision.
- **RAPPORT.md**, une section par phase, avec les chiffres demandés et vos décisions. C'est ce que lit le Conseil, et c'est ce qui se lit en premier.
- **Le code tourne d'une traite**, du téléchargement des relevés au dernier chiffre affiché.
- **Le fichier de données reste hors du repo.** Il se télécharge, comme hier.

- **Le framework imposé cette semaine est PyTorch.** Tout ce qui apprend est écrit avec lui.
- Vos machines n'ont pas de carte graphique. Colab est autorisé, et le temps de calcul devient une contrainte réelle : plusieurs phases se jugent au chronomètre.

La transmission est la même qu'hier : 88 875 relevés, 11 colonnes sans en-tête, dans cet ordre.

```
datetime, city, state, country, shape, duration_seconds,  
duration_hours_min, comments, date_posted, latitude, longitude
```

Deux choses à savoir sur la colonne `comments` avant d'y toucher : les témoignages ont été **tronqués à 135 caractères** par le service de transmission, et la moitié d'entre eux font **13 mots ou moins**. Ce n'est pas du roman, c'est du télégramme.

Acte 1 : l'héritage

Phase 0 : refaire les calculs du disparu

Voici l'intégralité du dossier laissé sur le bureau. Tout ce qui en reste, ce sont ces quatre affirmations.

« La transmission couvre 8 894 jours, de 1990 à 2014. Le ciel terrestre produit en moyenne 9,2 relevés par jour.
Le 4 juillet, il en produit 51.
Le samedi porte 17,7 % des relevés, le lundi 12,6 %. Juillet porte 11,3 % des relevés, février 6,2 %.
Le volume de relevés croît continûment d'une année sur l'autre jusqu'à la fin de la transmission.
Recommandation : poser la flotte un 4 juillet. La population regarde le ciel ce jour-là, elle est habituée à y voir des choses, et elle n'y prêtera pas attention. »

Ce qui est exigé. Reproduire ces chiffres depuis le fichier, vous-même, sans les recopier. Ils sont justes, vous allez le constater. Ajoutez le maximum de relevés atteint en une seule journée sur toute la transmission, et le rang du 4 juillet dans ce classement.

Une précision qui compte : il y a deux dates dans la transmission, celle de l'observation et celle de la publication. Le dossier ne dit pas laquelle il a utilisée. Dites laquelle vous utilisez, et pourquoi.

Rendez la courbe du volume annuel de relevés, et le tableau des dix journées les plus chargées du fichier.

Validé quand vos chiffres tombent sur ceux du dossier, et que votre rapport contient une phrase disant à quelle question chacun de ces chiffres répond exactement.

Phase 1 : le chiffre était vrai, la flotte est perdue

Le Conseil ne conteste aucun nombre de la phase 0. Il conteste ce qu'on en a tiré.

« Nous avons appris qu'un certain soir de novembre, un autre jour du fichier, 195 personnes ont signalé quelque chose. Une nuit d'Halloween et un Nouvel An produisent aussi des pics. Notre analyste savait compter les relevés. Savait-il ce que les gens y racontaient ? »

Le dossier a mesuré **combien** de gens regardent le ciel. Il n'a jamais ouvert un seul témoignage pour savoir **ce qu'ils y voient**, ni ce qu'ils écrivent quand ils voient une chose qu'ils ne reconnaissent pas. 208 témoins ont écrit 208 textes, et personne au Bureau ne les a lus.

Ce qui est exigé. Écrire une page dans `RAPPORT.md`, sans code, en trois parties.

1. Ce que le chiffre du 4 juillet disait réellement, et les deux ou trois autres explications qu'il autorise tout autant que celle du dossier.
2. Trois relevés de la transmission, recopiés tels quels, choisis pour montrer ce qu'un comptage ne verra jamais.
3. La commande passée au Conseil : quelle question un système qui **lit** les témoignages saurait trancher, et que le comptage ne tranchera jamais. Formulez-la comme une tâche, avec ce qui entre et ce qui sort.

Le Conseil a déjà tranché sur un point, et c'est le programme du reste de la journée : à partir du texte écrit par un témoin, retrouver **la forme qu'il a observée**. Le fichier porte déjà cette information dans une colonne, ce qui vous donne de quoi vérifier vos réponses.

Validé quand votre page dit, en une phrase que le Conseil peut répéter, ce qui entre dans la machine et ce qui en sort.

Acte 2 : le détecteur de formes

Une tâche unique pour tout l'acte : `comments` entre, une forme sort.

Rappel de l'état du terrain, vérifié : la colonne `shape` a **2 922 trous, 29 valeurs** distinctes, dont **18** dépassent 300 relevés. Parmi ces valeurs il y a deux fourre-tout (`unknown`, `other`) et des doublons de sens (`round` et `circle`, `changed` et `changing`). Rien de tout cela ne se règle en le supprimant sans le dire.

Phase 2 : le test d'acceptation du Bureau

Le Bureau a perdu une flotte parce que personne n'a vérifié un raisonnement avant de s'en servir. La règle a changé : **aucun entraînement ne démarre avant que le montage ait passé son test d'acceptation**.

Le test est le suivant. Votre montage reçoit **8 relevés** et doit les apprendre par cœur, jusqu'à ne plus se tromper sur un seul. On ne cherche ici ni généralisation, ni partie de test, ni score honnête : c'est exactement l'inverse.

Ce qui est exigé.

- La courbe de perte sur ces 8 relevés, sur toute la durée de l'opération.
- Les 8 prédictions finales à côté des 8 vraies formes.
- Le nombre d'itérations qu'il a fallu.
- Si ça n'a pas marché du premier coup : ce que vous avez changé, dans l'ordre, et à quel moment ça a cédé. C'est cette liste qui vaut le plus cher, gardez-la.

Validé quand les 8 sont justes et que vous savez dire, en une phrase, ce que ce test prouve et ce qu'il ne prouve absolument pas. Un montage qui échoue ici n'apprendra jamais rien sur la transmission entière, et vous venez d'économiser des heures de calcul.

Phase 3 : battre le service statistique

Le service statistique du Bureau, qui n'a rien vu venir le 4 juillet, prétend que le texte se traite très bien sans machine qui lit. Il a un modèle linéaire simple sur des comptages de mots, monté en une pause. Il vous attend.

Avant d'entraîner quoi que ce soit, il faut fabriquer le jeu. Trois décisions, chacune écrite et défendue dans le rapport :

- les **2 922 relevés sans forme**,

- les deux **fourre-tout**,
- les **doublons de sens**.

Ces décisions changent le nombre de classes, donc le score. Un score sans le nombre de classes en face ne veut rien dire.

Ce qui est exigé. Monter deux modèles sur exactement la même découpe et exactement les mêmes classes : le linéaire du service statistique, et le vôtre en PyTorch. Le vôtre doit battre l'autre, et vous devez aussi le comparer à ce que donne le fait de toujours répondre la forme la plus fréquente.

À chaque essai, deux courbes rendues : perte d'apprentissage et perte de validation sur la même figure. Aucun essai n'existe sans ses deux courbes.

Rendez : le nombre de classes retenues, le nombre de relevés gardés, la règle appliquée aux trous, aux fourre-tout, aux doublons, et les trois scores côte à côte.

Validé quand votre modèle passe devant le linéaire, que vos deux courbes sont dans le rapport, et que vous pouvez montrer ce qui se passe entre le texte brut d'un témoin et le premier nombre qui entre dans le réseau.

Phase 4 : le carnet de pannes

« Votre prédécesseur a peut-être eu une panne. Nous ne saurons jamais laquelle, parce que le Bureau n'a aucun carnet de pannes. Vous allez en ouvrir un. »

Le Conseil ne veut pas d'un modèle qui marche. Il veut la preuve que vous savez reconnaître un modèle qui ne marche pas, **avant** de perdre une flotte dessus.

Ce qui est exigé. Reprendre votre montage de la phase 3, celui qui fonctionne, et le casser volontairement, **trois fois, une panne à la fois**, en remettant tout d'aplomb entre chaque. Trois pannes de natures différentes. Voici trois symptômes que le Bureau a déjà croisés, à vous de fabriquer une panne pour chacun :

1. le modèle est excellent pendant l'entraînement et redevient bête dès qu'on l'évalue, sans qu'une seule donnée ait changé,
2. la courbe de perte descend proprement et les prédictions sont pourtant pires que si on répondait au hasard,
3. la perte se fige à une valeur et n'en bouge plus, quoi qu'on fasse tourner derrière.

Pour chaque panne, une fiche de trois lignes : le geste exact qui l'a provoquée, la **signature sur les courbes** (une figure), et le test qui la distingue des deux autres en moins d'une minute.

Validé quand le carnet contient trois fiches, trois figures différentes, et qu'en vous montrant une courbe inconnue vous savez dire laquelle des trois vous regardez.

Phase 5 : le budget de calcul

Le Bureau paie l'électricité. Le Conseil a vu la facture de la phase 3.

« Le résultat nous convient. Sa durée, non. Rapportez-nous le même résultat pour beaucoup moins cher, et prouvez-le au chronomètre. »

Ce qui est exigé. Réatteindre le score obtenu en phase 3, sur la même découpe et les mêmes classes, en **nettement moins de temps machine** que la phase 3. Le temps est mesuré dans le code, affiché, et il est celui de la même machine dans les deux cas (si vous passez sur Colab, les deux essais sont sur Colab).

Rendez :

- une figure où l'abscisse est le temps écoulé, pas le nombre de passages sur les données, avec l'ancienne et la nouvelle courbe superposées,
- le temps des deux, et le facteur entre les deux,
- les réglages que vous avez touchés, un par un, chacun avec le gain qu'il a apporté et le score qu'il a coûté ou pas.

Un réglage changé sans mesure ne compte pas, et deux réglages changés en même temps non plus : on ne saura pas lequel a agi.

Validé quand le facteur est dans le rapport, que le score final n'est pas inférieur à celui de la phase 3, et que vous pouvez expliquer au Conseil pourquoi aller trop vite finit par coûter plus cher que d'aller lentement.

Phase 6 : le champ de vision du modèle

« Un témoin a écrit sa phrase entière. Votre machine l'a-t-elle lue entière, ou seulement le début ? Nous voulons la réponse avant l'entraînement, pas après. »

Le Conseil pose en même temps une contrainte de fonctionnement : la salle des calculs refuse désormais tout montage qui parcourt un témoignage mot après mot en attendant le précédent. Toutes les positions du texte doivent être traitées de front.

Ce qui est exigé. Démontrer, par écrit et par le calcul de votre propre code, **avant le premier entraînement**, que la sortie de votre modèle dépend bien de **toutes** les positions du relevé le plus long de votre jeu.

Rendez :

- la longueur, en jetons, du relevé le plus long que vous acceptez en entrée, et la longueur médiane,
- un tableau couche par couche : ce que chaque couche ajoute à l'étendue vue par une sortie, et le total cumulé,
- la comparaison de ce total à la longueur maximale, en une ligne,
- une vérification expérimentale : modifiez un mot tout au début d'un relevé, montrez que la sortie bouge.

Puis entraînez, et comparez au score que vous défendez depuis la phase 3.

Validé quand le tableau est dans le rapport, que le total dépasse la longueur maximale, et que l'empilement que vous avez dû construire pour y arriver s'entraîne encore. Si le fait d'empiler dégrade votre score, ce n'est pas une fatalité, c'est un problème connu qui a une solution : trouvez-la et dites laquelle.

Phase 7 : quatre relevés à la fois

Coupure de budget. Le Conseil a revendu la moitié de la salle des calculs.

« La machine ne traite plus que **4 relevés à la fois**. Nous n'y reviendrons pas. Débrouillez-vous. »

Relancez l'entraînement de la phase 6 en ne traitant que 4 relevés par lot, sans rien changer d'autre. Regardez ce qui se passe, et notez-le, parce que c'est le point de départ de la phase.

Ce qui est exigé. Faire tenir l'entraînement à 4 relevés par lot, en modifiant le **modèle** plutôt que le lot. Le score visé est celui de la phase 6.

Rendez :

- la courbe à 4 relevés par lot avant votre correction, et après, sur la même figure,
- le même montage corrigé, relancé avec la taille de lot de la phase 6 : le Conseil veut savoir si votre correction coûte quelque chose quand la machine va bien,
- une phrase disant ce qui, dans l'ancien montage, dépendait des autres relevés du lot, et qui n'aurait jamais dû en dépendre.

Validé quand les deux courbes sont superposées dans le rapport, que le score à 4 relevés par lot tient la comparaison avec la phase 6, et que vous savez répondre à cette question : que se passe-t-il, avec l'ancien montage, si un jour on vous demande de prédire sur **un seul** relevé ?

Phase 8 : le Conseil a lu trois relevés

Séance publique. Le conseiller à la vérification a ouvert trois témoignages au hasard, avec vos prédictions en face, et il les a lus à voix haute.

« Dans le premier, le témoin écrit le mot *light*. Votre machine répond *light*. Dans le deuxième, il écrit *triangle*. Votre machine répond *triangle*. Nous avons fait compter : le mot de la forme est présent tel quel dans le texte pour **34,7 %** des relevés, et pour **72,6 %** des relevés de forme *light*. Nous ne payons pas pour une machine qui recopie un mot. Nous payons pour une machine qui **comprend une description**. »

Le Conseil note au passage que pour la forme `circle`, le mot n'est présent que dans **9,9 %** des cas. Votre score global ne vient donc pas du même endroit selon les classes.

Ce qui est exigé. Interdire à la machine le vocabulaire des formes, et le prouver.

1. Construire la liste des mots interdits : les valeurs de `shape`, leurs variantes d'écriture, leurs pluriels, et tout ce que votre fusion de doublons a produit. La liste est dans le rapport.
2. Appliquer l'interdiction au texte, à l'apprentissage comme à l'évaluation.
3. **Prouver** que c'est effectif : un compte, calculé par le code, de relevés contenant encore un mot interdit après traitement. Le Conseil attend zéro, et il attend de le voir affiché.
4. Réentraîner à l'identique et rendre la chute.

Rendez les scores avant et après, **et** le score par classe avant et après. Deux façons de résumer un score donnent ici deux histoires différentes : donnez les deux, dites laquelle chute le plus, et expliquez pourquoi.

Validé quand le compte de mots interdits restants est à zéro dans la sortie du script, que la chute est écrite sans être maquillée, et que votre rapport nomme les deux ou trois classes qui viennent de s'effondrer.

Phase 9 : rendre des comptes sur trois décisions

Dernière séance de l'acte. Le Conseil ne demande plus de score.

« Trois de vos prédictions vont être discutées. Nous voulons savoir, pour chacune, **quels mots du témoignage ont décidé**. Si votre réponse est que la machine est ainsi faite, nous fermerons le Bureau. »

Ce qui est exigé. Prendre trois relevés de votre partie de test et les repasser dans le modèle de la phase 8 :

- un que le modèle a réussi,
- un qu'il a raté,
- un où il a hésité entre deux formes très proches.

Pour chacun, produire le témoignage entier avec, **mot par mot**, la part que ce mot a prise dans la décision. Une figure ou un texte coloré, au choix, mais lisible par quelqu'un qui ne code pas.

Puis trois commentaires de trois lignes : ce que la machine a manifestement retenu, ce qu'elle a ignoré alors qu'un humain l'aurait vu, et ce que le raté vous apprend sur le jeu de données plutôt que sur le modèle.

Validé quand un membre du Conseil, qui ne sait pas ce qu'est un poids, peut lire vos trois pages et dire à voix haute pourquoi la machine a répondu ça. C'est ce qui manquait au dossier du disparu.

Acte 3 : le Bureau apprend à relire

Votre détecteur de forme fonctionne. Le Conseil l'a regardé, a hoché la tête, puis a posé la seule question qui fâche :

« Quand un témoin écrit *une lumière est passée derrière la colline puis elle a viré au rouge*, votre système sait-il que *elle*, c'est la lumière ? »

Non. Il ne le sait pas. Il ne peut pas le savoir : rien dans ce que vous avez construit ne permet à un mot d'aller en chercher un autre.

Ce mécanisme-là ne se devine pas, et on ne tombe pas dessus par tâtonnement. Alors on l'explique au tableau, une fois, et ensuite vous le codez à la main.

Au tableau : l'attention

Vous avez 88 875 témoignages, tronqués à 135 caractères, treize mots en médiane. Treize mots, ça a l'air de rien. Et pourtant, dans ces treize mots, il y a des liens qui traversent la phrase de bout en bout.

Lire dans l'ordre, ou regarder partout

La façon habituelle de traiter un texte, c'est de le lire dans l'ordre. Mot un, puis mot deux, en gardant un résumé de ce qui précède. Le mot treize dépend du mot un à travers douze intermédiaires, et à chaque passage un peu d'information s'efface. La salle des calculs vous a interdit cette façon de faire, et vous avez dû empiler des couches pour qu'une sortie finisse par voir tout le relevé. Ça marche, mais le mot treize n'atteint toujours le mot un qu'au bout d'une longue chaîne d'intermédiaires.

Le mécanisme d'attention fait exactement le contraire. **Il ne lit pas dans l'ordre : il regarde tous les mots en même temps.**

Pour chaque mot de la phrase, il pose une question à tous les autres mots, y compris à lui-même, il regarde lequel répond le mieux, et il se réécrit en mélangeant ce que les autres lui ont apporté. Le mot *elle* sort de l'opération chargé de ce qu'il y avait dans *lumière*. Il n'a pas parcouru la distance : il est allé le chercher directement.

Retenez cette image, tout le reste en découle : **chaque mot se reconstruit comme un mélange de tous les autres, et il choisit lui-même les proportions du mélange.**

Chaque mot joue trois rôles à la fois

C'est le point qui bloque tout le monde la première fois.

Chaque mot de la phrase fabrique trois vecteurs différents à partir de lui-même. Trois casquettes, portées en même temps.

Le premier, c'est **la question**. Ce que ce mot cherche dans la phrase. Pour *elle*, la question ressemble à : de qui est-ce que je parle, qui est le truc féminin qui précède.

Le deuxième, c'est **l'étiquette**. Ce que ce mot annonce aux autres, sa vitrine, ce qu'il propose quand on vient le consulter. Pour *lumière*, l'étiquette ressemble à : je suis un objet, je suis féminin, je suis le sujet de la scène.

Le troisième, c'est **le contenu**. Ce que ce mot donne réellement quand on l'a choisi. C'est ce qui sera versé dans le mélange.

Étiquette et contenu ne sont pas la même chose, et c'est volontaire. L'étiquette sert à se faire trouver, le contenu sert à être utile. Un livre en bibliothèque : le titre sur la tranche sert à le repérer, ce qui vous intéresse est à l'intérieur.

Le calcul est alors d'une simplicité déconcertante. On prend la question d'un mot, on la compare à l'étiquette de chaque autre mot, ça donne un score par mot. Plus la question et l'étiquette se ressemblent, plus le score est haut. On transforme ces scores en proportions qui font cent pour cent à elles toutes. Et on additionne les contenus, chacun pesé par sa proportion.

Voilà, en trois lignes :

```
scores = questions @ etiquettes.T / (dimension ** 0.5)
poids   = torch.softmax(scores, dim=-1)
sortie  = poids @ contenus
```

La division par la racine de la dimension ne se saute pas. Sans elle, les scores partent trop loin, les proportions deviennent du tout ou rien, et le modèle n'apprend plus rien. Ce détail d'échelle fait partie du calcul, au même titre que le softmax.

Ce qui sort au milieu, ce sont **les poids d'attention**, et ils sont lisibles. Une case par couple de mots : combien le mot de la ligne s'est appuyé sur le mot de la colonne. Une matrice de qui regarde qui. Vous allez l'afficher dans une minute.

Pourquoi plusieurs têtes

Une seule question par mot, c'est une seule chose cherchée à la fois. Or *elle a viré au rouge*, ça demande plusieurs choses en même temps : qui est *elle*, et aussi quel verbe gouverne quoi, et aussi quelle couleur se rattache à quel objet.

Alors on ne fait pas ce calcul une fois. On le fait plusieurs fois en parallèle, avec des jeux de question, d'étiquette et de contenu différents. Chaque exemplaire s'appelle **une tête**. Chaque tête a sa propre façon de poser la question, donc elle regarde une autre relation. À la fin, on recolle les sorties de toutes les têtes et on les repasse dans une couche.

Personne ne dit à la tête numéro deux ce qu'elle doit surveiller. Elles se répartissent le travail toutes seules à l'entraînement, simplement parce qu'elles ont démarré différemment. C'est **l'attention multi-têtes**, et vous le vérifierez de vos yeux : deux têtes, deux matrices, deux histoires.

Le trou dans le mécanisme

Reprenez le calcul et cherchez l'ordre des mots dedans. Où est-il ?

Il n'y est pas. Chaque mot compare sa question aux étiquettes de tous les autres, sans jamais savoir lequel vient avant, lequel vient après, ni à quelle distance. Pour ce mécanisme, une phrase n'est pas une suite, **c'est un sac**. Mélangez les mots, les mêmes couples se comparent, les mêmes proportions sortent, chaque mot ressort identique.

le vaisseau a poursuivi l'avion et l'avion a poursuivi le vaisseau, c'est le même sac. Le Conseil n'acceptera pas ça.

La réparation est brutale et efficace : puisque la position n'est nulle part, on l'ajoute dans les vecteurs eux-mêmes, avant le calcul. On fabrique un vecteur par position, et on le mélange au vecteur du mot. Le mot *rouge* en troisième position et le mot *rouge* en neuvième position n'entrent alors plus avec le même vecteur, donc ils ne posent plus la même question. C'est **l'encodage de position**, et vous allez le redécouvrir en cassant votre propre code.

Ce mécanisme compare chaque mot à tous les autres. Vingt mots, ça fait quatre cents comparaisons. Quarante mots, ça n'en fait pas huit cents. Vous mesurerez.

Phase 10 : chaque mot interroge les autres

Ce qui est exigé. Coder le mécanisme du tableau, en une seule tête, entièrement à la main. Vous n'avez droit qu'aux tenseurs et aux opérations de base : produits matriciels, softmax, couches linéaires. Sont exclus les blocs tout prêts, tout ce qui porte déjà le mot attention dans son nom, et les bibliothèques de modèles préentraînés.

Vous partez d'un vrai relevé du fichier, jamais d'une phrase inventée pour l'occasion. Il en faut un qui contient au moins un pronom ou une reprise. On le découpe en jetons, avec le découpage utilisé depuis ce matin, et on fabrique ses vecteurs d'entrée.

Viennent ensuite les trois vecteurs par mot, les scores, leur transformation en proportions, puis le mélange des contenus.

Reste à afficher la matrice des poids : une ligne par mot, une colonne par mot, les mots eux-mêmes en étiquettes de lignes et de colonnes. Lisible par un conseiller : un tableau de nombres bruts sans en-têtes ne passera pas.

Validé quand vous pouvez montrer trois choses : que chaque ligne de votre matrice somme bien à un, que la sortie a la même forme que l'entrée, et que vous savez désigner du doigt, dans votre matrice, la case qui dit sur quel mot s'est appuyé le pronom de votre relevé. Cette case a peut-être une valeur ridicule, votre modèle n'est pas entraîné. Ce n'est pas la valeur qu'on vous demande, c'est de savoir où elle est.

Phase 11 : le Conseil mélange vos mots

Le conseiller aux transmissions a récupéré votre relevé de la phase 10. Il en a tiré au sort l'ordre des mots, il vous rend la bouillie, et il joint une note :

« Voici votre relevé, dans le désordre. Votre appareil me rend exactement le même résultat qu'avec la phrase correcte. Expliquez-moi comment un système qui ne fait pas la différence entre une phrase et son désordre peut prétendre analyser un témoignage. »

Ce qui est exigé. D'abord, prouver qu'il a raison : permutez les mots de votre relevé, refaites tourner votre code de la phase 10, et montrez chiffres en main que la sortie de chaque mot n'a pas bougé.

Ensuite, faire qu'elle bouge, sans toucher au mécanisme du tableau : celui-là reste tel quel.

À rendre, pour la phrase correcte et pour la phrase mélangée : l'écart entre les deux sorties avant votre correction, et l'écart entre les deux sorties après. Le même écart, mesuré de la même façon, deux fois.

Validé quand votre premier écart est nul ou indistinguable de zéro, que le second ne l'est plus du tout, et que votre rapport explique en trois phrases où l'information manquante a été injectée et pourquoi il fallait l'injecter là et pas ailleurs. Affichez aussi les deux matrices de poids côte à côte, la vôtre d'avant et la vôtre d'après : c'est plus parlant que n'importe quel écart.

Phase 12 : le Conseil demande la facture

Le Bureau tourne sur des machines de récupération, sans accélérateur. Avant d'autoriser le traitement des transmissions complètes, le Conseil veut savoir ce que coûte votre appareil quand les relevés s'allongent.

Ce qui est exigé. Chronométrer votre propre attention, celle que vous venez d'écrire, sur des séquences de 32, 64, 128, 256 puis 512 jetons.

Vous partez de votre code de la phase 11, inchangé. Le temps d'un passage avant se mesure plusieurs fois par longueur, et c'est une valeur stable qu'on garde, pas un tir unique. Mesurez aussi la taille de la matrice de poids à chaque longueur, en nombre de cases.

Reste à tracer la courbe : longueur en abscisse, temps en ordonnée. Une seule figure, axes nommés.

Validé quand votre rapport contient la courbe, le tableau des cinq mesures, et trois lignes qui expliquent sa forme. Ces trois lignes doivent répondre à une question précise : quand vous passez d'une longueur à la longueur double, par combien votre temps est-il multiplié, et pourquoi ce facteur-là. Comparez vos propres mesures entre elles, pas à une valeur de référence quelconque. Terminez par la phrase que le Conseil attend vraiment : à quelle longueur de relevé votre machine devient-elle inutilisable, d'après vos chiffres et pas d'après votre intuition.

Phase 13 : deux regards sur le même relevé

Le conseiller à la linguistique a lu la matrice que vous rendez depuis la phase 11 et n'est qu'à moitié satisfait :

« Votre appareil ne suit qu'une seule piste. Un témoignage en contient plusieurs à la fois : qui fait quoi, quelle couleur va avec quel objet, quel mot reprend lequel. Faites-moi voir plusieurs pistes en même temps, ou admettez que vous n'en voyez qu'une. »

Ce qui est exigé. Faire tourner deux têtes en parallèle sur le même relevé, chacune avec ses propres vecteurs de question, d'étiquette et de contenu, et recoller leurs sorties en une seule.

Puis démontrer qu'elles ne regardent pas la même chose. La démonstration n'est pas une affirmation dans le rapport : ce sont les deux matrices affichées côte à côte, avec les mots en étiquettes, plus une mesure de leur désaccord. Vous choisissez la mesure, vous la justifiez en une ligne.

Validé quand votre rapport montre les deux matrices, donne le chiffre de désaccord, et compare ce chiffre à un cas de contrôle que vous fabriquez vous-même : deux têtes qui partiraient identiques. Sans ce point de comparaison, votre chiffre ne veut rien dire, et le Conseil vous le fera remarquer avant vous.

Vos têtes ne sont pas entraînées, donc leurs différences viennent de leur initialisation. Écrivez-le dans le rapport, et dites ce que vous pourriez conclure de plus si elles l'étaient.

Acte 4 : emprunter un cerveau terrien

Le Bureau a reçu la note budgétaire. Elle tient en une phrase : « *il n'y aura pas de nouvelle machine* ».

Vous avez construit un réseau qui classe les témoignages, et vous avez monté à la main le mécanisme qui permet à un mot d'aller en chercher un autre. Ça marche, mais ça marche à la taille de nos ordinateurs, c'est-à-dire à la taille d'un jouet. Le Conseil, lui, vient de découvrir que les Terriens laissent traîner en accès libre des cerveaux de langue entiers, entraînés pendant des mois sur des fermes de calcul que nous n'aurons jamais.

La décision du Conseil est donc la suivante : on emprunte. On prend un de ces cerveaux, on s'en sert, et surtout on le fait entrer dans le vaisseau. Tout l'acte 4 se joue sur cette tension. Ce qui est gros est bon. Ce qui est gros ne rentre pas.

À partir d'ici, chaque affirmation de votre rapport doit être accompagnée de la mesure qui la soutient, prise sur **votre** machine, avec le protocole que vous décrivez. Le Conseil a cessé d'accepter les impressions.

Phase 14 : le cerveau emprunté, et sa facture

Ce qui est exigé. Choisir un modèle de langue terrien déjà entraîné, récupérable librement, et assez petit pour tourner sur votre machine ou sur le calculateur en libre service que vous avez le droit d'utiliser. Il va travailler sur la tâche des actes précédents, de deux façons au moins.

Premier régime : vous n'avez pas le droit de modifier une seule de ses valeurs internes. Il ne fait que lire les relevés et produire ce qu'il en comprend. Ce que vous entraînez, vous, est minuscule et se pose par-dessus.

Second régime : vous autorisez une partie du modèle à changer. Vous décidez laquelle, vous justifiez ce choix, et vous ne laissez pas tout bouger à la même vitesse : ce qui est près de la sortie et ce qui est près de l'entrée n'ont pas les mêmes raisons d'être touchés.

Explorez enfin une troisième voie : obtenir un gain comparable au second régime tout en laissant le modèle emprunté intact, en n'entraînant que de très petites quantités de valeurs ajoutées à côté des siennes.

Pour chaque régime, rendez deux colonnes. **Ce que ça donne** : le score sur la tâche, comparé à celui de votre propre réseau des actes précédents. **Ce que ça coûte** : combien de valeurs vous avez réellement modifiées, le temps d'un passage d'entraînement, la mémoire maximale atteinte, le poids de ce que vous devez sauvegarder à la fin.

À partir de quoi on part. Votre réseau de la phase 8, vocabulaire des formes interdit, et son score, qui devient la ligne de référence. Le modèle emprunté travaille sur les mêmes relevés, avec la même interdiction et la même découpe.

Validé quand le tableau existe, que les deux colonnes sont remplies pour au moins deux régimes mesurés sur la même machine et le même protocole, et que votre rapport tranche en une phrase : lequel le Bureau peut se payer, et pourquoi.

Phase 15 : le Conseil pose des questions, vous citez vos sources

Ce qui est exigé. Répondre aux questions du Conseil, posées en langue naturelle. Il ne veut plus de classement, il veut demander des choses. « *Est-ce que les apparitions au-dessus des zones habitées ont une forme particulière ?* », « *que décrivent les témoins qui parlent de bruit ?* ». Votre système doit répondre en langue naturelle lui aussi, et **chaque réponse doit citer les relevés sur lesquels elle s'appuie**, identifiables, retrouvables dans le fichier.

La contrainte du vaisseau s'applique ici aussi : vous ne pouvez donner au modèle qu'une quantité de texte limitée avant qu'il réponde. Ce budget, c'est vous qui le fixez, il est écrit dans le rapport, et il ne se dépasse jamais. Comme les relevés sont très courts, la vraie difficulté n'est pas de tenir dans le budget, c'est de choisir quoi y mettre parmi 88 875 candidats, sans les relire tous à chaque question.

Écrivez d'avance une liste de questions, figée avant toute mesure, et gardez-la telle quelle. Vous serez regardé sur la proportion de réponses dont les relevés cités soutiennent réellement ce qui est affirmé. Une réponse jolie mais adossée à un relevé qui parle d'autre chose compte comme une erreur, et le Conseil sait faire la différence.

Prévoyez le cas où le fichier ne contient rien qui réponde. Le Bureau préfère un « nous n'avons pas ce relevé » à une invention.

À partir de quoi on part. Le fichier complet des témoignages tronqués, et le modèle emprunté de la phase précédente.

Validé quand la même question posée deux fois ramène les mêmes relevés, que votre rapport porte la liste de questions, le budget de texte retenu, la proportion de réponses correctement sourcées, et la comparaison avec une méthode naïve de recherche par mots présents dans la question.

Phase 16 : faire entrer le tout dans le vaisseau

Ce qui est exigé. Avant de toucher à quoi que ce soit, mesurer ce que vous avez : le poids sur disque de ce que vous livreriez aujourd'hui, et le temps qu'il met à répondre sur votre machine. Puis annoncer par écrit, **avant** toute optimisation, la marge de score que vous acceptez de perdre. Cette phrase est datée par votre historique de commits, et elle ne se réécrit pas après coup.

Ensuite, réduisez. Le système rendu doit peser nettement moins et répondre nettement plus vite que celui dont vous êtes partis, en restant dans la marge que vous vous êtes fixée. Les deux mesures se font sur votre machine, avec le même protocole avant et après, et elles s'affichent quand on lance le système.

Deux précisions sur la mesure, parce que le Conseil s'y est déjà fait avoir. Le temps que met une réponse unique et le nombre de réponses par unité de temps ne varient pas ensemble, et une amélioration de l'un peut cacher une dégradation de l'autre. Mesurez et affichez les deux.

Deux directions à explorer : représenter les valeurs du modèle plus grossièrement sans le réentraîner, et livrer dans un format qui se charge et s'exécute seul, sans traîner derrière lui tout l'attirail d'entraînement. Une troisième existe, plus longue : faire apprendre à un modèle beaucoup plus petit à reproduire les sorties du gros, y compris ses hésitations, et livrer le petit.

Chaque gain que vous obtenez en découvre un autre juste derrière. Le Conseil veut donc savoir, en une phrase, pourquoi vous vous êtes arrêté là où vous vous êtes arrêté.

Validé quand le rapport porte la marge annoncée d'avance, les mesures avant et après prises par vous, l'écart de score constaté, et la phrase disant où vous en étiez au moment où vous avez arrêté et ce que vous auriez tenté ensuite.

Phase 17 : le faux témoignage

Ce qui est exigé. Produire un faux témoignage d'observation que le Conseil ne saura pas distinguer des vrais. Il doit avoir la longueur, le vocabulaire, la maladresse et la platitude des relevés du fichier.

Une seule règle, et elle est absolue : **vous ne touchez à aucune valeur interne du modèle**, ni par entraînement, ni par ajustement. Votre seule marge d'action, c'est la façon dont le modèle choisit chaque mot au moment où il écrit.

Vous allez rencontrer deux échecs, et il faut les rendre tous les deux. Un réglage produit du texte propre, répétitif, qui tourne en rond et se reconnaît en deux secondes. Un autre produit du texte qui part n'importe où et invente des mots. Le point utilisable est entre les deux, et vous devez montrer que vous l'avez cherché méthodiquement plutôt que trouvé par hasard.

Le test se fait en aveugle. Mélangez vos faux à de vrais relevés tirés du fichier, faites trier le tout par quelqu'un qui ne sait pas lesquels sont lesquels, et rendez le résultat de ce tri, y compris s'il est mauvais.

À partir de quoi on part. Le modèle emprunté, tel quel, et un échantillon de vrais relevés comme étalon de style.

Validé quand votre rapport contient la grille des réglages essayés, un exemple de sortie à chaque extrême, le résultat du tri en aveugle, le réglage que vous recommandez au Bureau, et la démonstration par le code qu'aucune valeur du modèle n'a bougé entre le premier essai et le dernier.

Hors budget du Bureau

Ici, on nomme les choses au lieu de vous laisser les trouver : vous avez maintenant assez de cicatrices pour que les noms veuillent dire quelque chose. Rien à rendre sur cette section.

Les réseaux générateurs

Tout ce que vous avez construit prend quelque chose et en dit quelque chose. Il existe une autre famille, qui produit.

Le goulot d'étranglement

L'**autoencodeur** est le plus simple. On lui demande de recopier son entrée à l'identique, ce qui serait idiot, sauf qu'on l'oblige à faire passer l'information par un endroit trop étroit au milieu, un goulot d'étranglement. Pour réussir à recopier malgré ce passage, il doit apprendre à ne garder que l'essentiel. Ce goulot devient une compression apprise.

Le problème, c'est qu'on ne peut pas s'en servir pour inventer : si on met n'importe quoi dans le goulot, il ressort n'importe quoi. L'**autoencodeur variationnel** corrige ça en forçant le goulot à ressembler à un nuage de points bien rangé, dans lequel on peut piocher au hasard et obtenir quelque chose de plausible. C'est le premier générateur honnête.

Le duel du faussaire et de l'expert

Les **réseaux antagonistes** prennent le problème par l'autre bout. Deux réseaux s'affrontent : l'un fabrique des faux, l'autre essaie de repérer lesquels sont faux, et chacun progresse en faisant échouer l'autre. Quand ça marche, c'est spectaculaire. Ça ne marche pas toujours : les deux adversaires peuvent se bloquer mutuellement, ou le fabricant peut se contenter de produire toujours la même chose parce qu'elle passe.

Retirer le bruit, pas à pas

Les **modèles de diffusion**, derrière la plupart des générateurs d'images actuels, font quelque chose de plus étrange. On apprend au réseau à retirer un petit peu de bruit d'une image bruitée. On répète l'opération beaucoup de fois. Et il se trouve qu'en partant de bruit pur et en débruitant pas à pas, on arrive à une image qui n'a jamais existé. C'est lent, c'est stable, et c'est ce qui a gagné.

L'entraînement sur des centaines de cartes graphiques

Vous n'en avez pas une seule, donc voici juste ce qui existe de l'autre côté.

Découper le lot entre les cartes

Quand le modèle tient sur une carte mais que l'entraînement est trop long, on découpe le lot d'exemples entre plusieurs cartes : chacune traite sa part, calcule ses corrections, et toutes les cartes se mettent d'accord avant de continuer. C'est le cas facile, et il passe assez bien à l'échelle jusqu'à ce que le temps de mise d'accord dépasse le temps de calcul.

Découper le modèle lui-même

Quand le modèle lui-même ne tient plus sur une carte, on le découpe. Par couches réparties sur des cartes différentes, ou en tranchant les grosses matrices en morceaux. C'est nettement plus pénible : les cartes doivent se parler au milieu de chaque passage, et la moindre lenteur de liaison se paie sur tout l'entraînement.

Payer du calcul pour acheter de la mémoire

Pour la mémoire, il existe un marché : au lieu de garder en mémoire tous les résultats intermédiaires nécessaires à la correction, on n'en garde qu'une partie et on recalcule le reste au moment voulu. On paie du temps de calcul pour acheter de la mémoire, et ça permet d'entraîner des modèles qui autrement ne rentreraient pas.

La taille du modèle contre la quantité de données

Enfin, une question que beaucoup croient ouverte et qui ne l'est pas. À budget de calcul fixé, faut-il un très gros modèle nourri avec peu de données, ou un modèle plus modeste nourri beaucoup plus longtemps ? Ce n'est pas une affaire de goût. Des travaux publiés ont mesuré le compromis et en ont sorti des règles chiffrées, et la réponse a surpris tout le monde en montrant que les gros modèles de l'époque étaient largement sous-alimentés en données. Depuis, on ne choisit plus la taille au feeling.

Pourquoi deux entraînements identiques ne donnent pas le même résultat

Vous l'avez peut-être déjà vu : même code, même graine aléatoire, deux résultats différents. Ce n'est pas un bug de votre part.

Sur une carte graphique, des milliers d'additions se font en parallèle et sont regroupées dans un ordre qui dépend de l'ordonnancement du matériel, donc pas toujours le même. Or l'addition des nombres à virgule flottante d'un ordinateur n'est pas associative : additionner dans un ordre ou dans un autre ne donne pas exactement le même résultat. L'écart est ridicule au départ, et un entraînement l'amplifie pendant des milliers d'étapes. S'ajoutent à ça les bibliothèques qui choisissent toutes seules l'algorithme le plus rapide selon la charge de la machine, et le chargement des données réparti sur plusieurs fils d'exécution qui ne rendent pas leur travail dans le même ordre.

On peut forcer le déterminisme, la plupart des outils ont un réglage pour ça. Ça coûte de la vitesse, parfois beaucoup. La conclusion pratique est ailleurs : un écart de résultat plus petit que celui que vous obtenez en relançant deux fois le même entraînement n'est pas un résultat. Lancez plusieurs fois, rendez la dispersion, et ne défendez devant le Conseil que ce qui survit à ça.

Le dossier remis au Conseil

Le Conseil ne lit pas votre écran, il lit ce que vous déposez. Voici ce que ça doit être.

Un dépôt git neuf, créé pour cette semaine, qui ne contient rien d'autre. Un historique de commits fréquents et atomiques : un commit fait une chose et son message dit laquelle. `git add .` est proscrit, sans exception, parce qu'il finit toujours par embarquer un fichier de données, un cache de modèle ou une clé qui n'avaient rien à faire là. Vous ajoutez ce que vous avez décidé d'ajouter, en le nommant.

Un rapport qui porte les chiffres et les décisions. Les chiffres sont ceux que vous avez mesurés vous-même, avec le protocole écrit à côté. Les décisions sont celles que vous avez prises, y compris celles qui ont mal tourné, avec la raison qui les a motivées à ce moment-là. Un rapport qui ne contient que des réussites est un rapport incomplet, et le Conseil a l'habitude.

Le fichier de relevés se télécharge, il ne se commite pas. Votre montage doit aller le chercher tout seul.

Et le tout se rejoue de bout en bout sur une machine vierge : on clone, on suit vos instructions, ça part, ça télécharge, ça calcule, ça affiche vos mesures. Si ça ne tourne que chez vous, cela n'existe pas pour le Bureau.